并查集（Union Find）

需求分析

- 假设有n个村庄，有些村庄之间有连接的路，有些村庄之间并没有连接的路

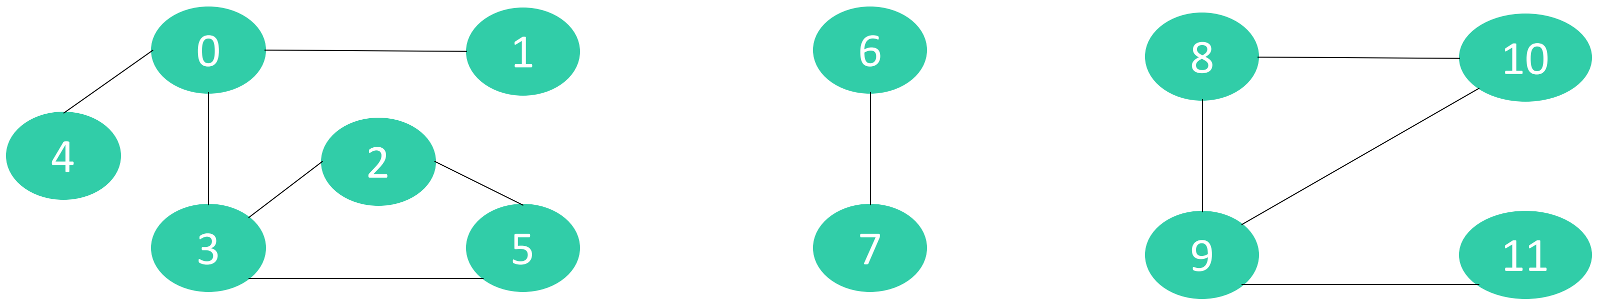

- 设计一个数据结构，能够快速执行2个操作
  - 查询2个村庄之间是否有连接的路
  - 连接2个村庄

- 数组、链表、平衡二叉树、集合（Set）？
  - 查询、连接的时间复杂度都是：$O(n)$

- 并查集能够办到查询、连接的均摊时间复杂度都是 $O(\alpha(n))$，$\alpha(n) < 5$
- 并查集非常适合解决这类“连接”相关的问题

并查集（Union Find）

■ 并查集也叫作不相交集合（Disjoint Set）

■ 并查集有2个核心操作

□ 查找（Find）：查找元素所在的集合（这里的集合并不是特指Set这种数据结构，是指广义的数据集合）

□ 合并（Union）：将两个元素所在的集合合并为一个集合

■ 有2种常见的实现思路

□ Quick Find

✓ 查找（Find）的时间复杂度：$O(1)$

✓ 合并（Union）的时间复杂度：$O(n)$

□ Quick Union

✓ 查找（Find）的时间复杂度：$O(\log n)$，可以优化至 $O(\alpha(n))$，$\alpha(n) < 5$

✓ 合并（Union）的时间复杂度：$O(\log n)$，可以优化至 $O(\alpha(n))$，$\alpha(n) < 5$

如何存储数据?

- 假设并查集处理的数据都是整型，那么可以用整型数组来存储数据

0	1	2	3	4	5	6	7
1	1	2	1	5	6	6	6

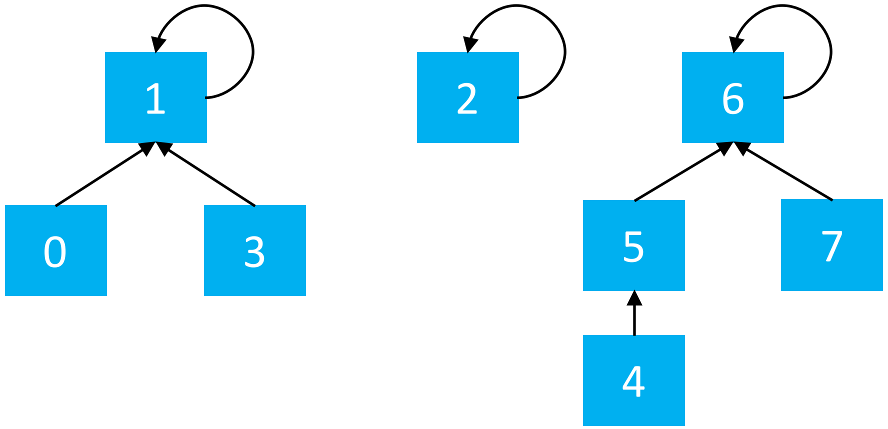

- 不难看出
  - 0、1、3 属于同一集合
  - 2 单独属于一个集合
  - 4、5、6、7 属于同一集合

- 因此，并查集是可以用数组实现的树形结构（二叉堆、优先级队列也是可以用数组实现的树形结构）

接口定义

```java
/**
 * 查找v所属的集合（根节点）
 */
int find(int v);

/**
 * 合并v1、v2所属的集合
 */
void union(int v1, int v2);

/**
 * 检查v1、v2是否属于同一个集合
 */
boolean isSame(int v1, int v2);
```

```java
public boolean isSame(int v1, int v2) {
    return find(v1) == find(v2);
}
```

初始化

- 初始化时，每个元素各自属于一个单元素集合

0	1	2	3	4
0	1	2	3	4

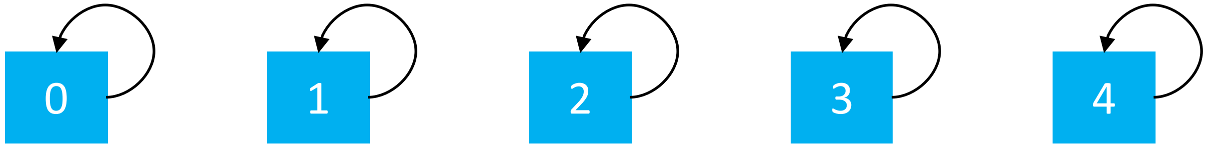


```java
private int[] parents;
public UnionFind(int capacity) {
    if (capacity < 0) {
        throw new IllegalArgumentException("Capacity must >= 1.");
    }
    parents = new int[capacity];

    for (int i = 0; i < parents.length; i++) {
        parents[i] = i;
    }
}
```

Quick Find – Union

- Quick Find 的 union(v1, v2)：让 v1 所在集合的所有元素都指向 v2 的根节点

0	1	2	3	4
0	1	2	3	4

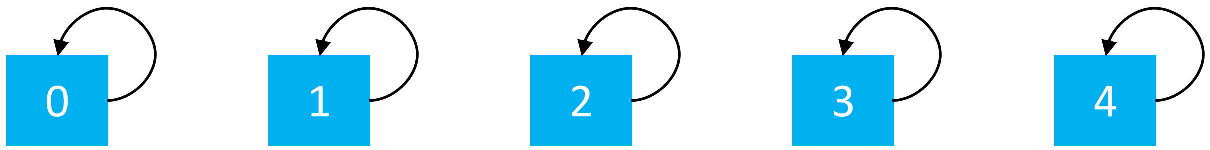

union(1, 0)

0	1	2	3	4
0	0	2	3	4

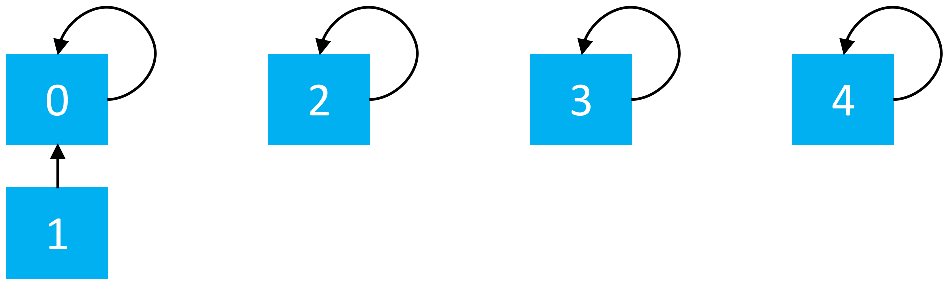

union(1, 2)

0	1	2	3	4
2	2	2	3	4

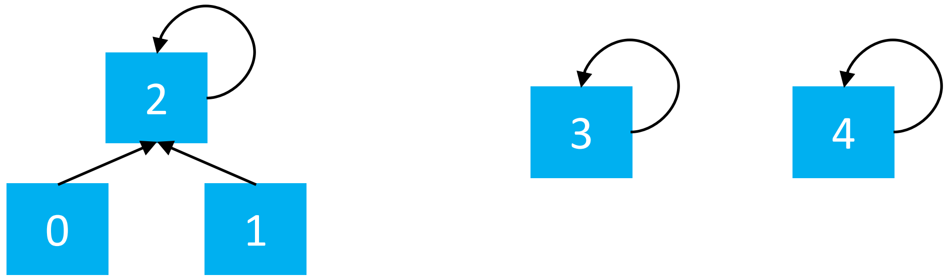

union(3, 4)

0	1	2	3	4
2	2	2	4	4

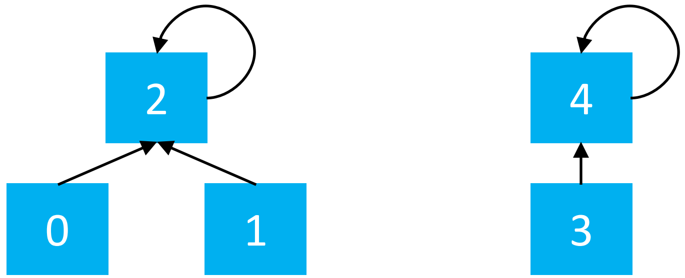

Quick Find – Union

0	1	2	3	4
2	2	2	4	4

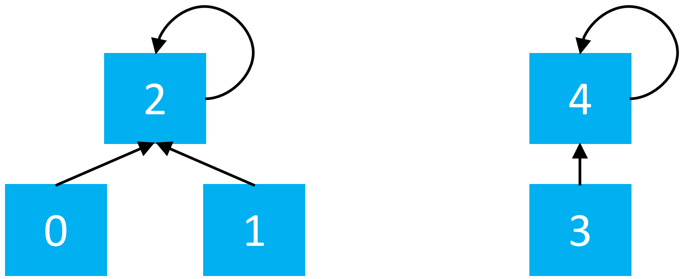

union(0, 3)

0	1	2	3	4
4	4	4	4	4

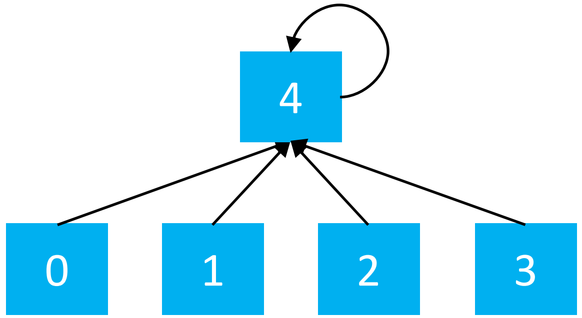

Quick Find – Union

```java
public void union(int v1, int v2) {
    int p1 = find(v1);
    int p2 = find(v2);
    if (p1 == p2) return;

    for (int i = 0; i < parents.length; i++) {
        if (parents[i] == p1) {
            parents[i] = p2;
        }
    }
}
```

■ 时间复杂度：O(n)

Quick Find – Find

0	1	2	3	4
2	2	2	4	4

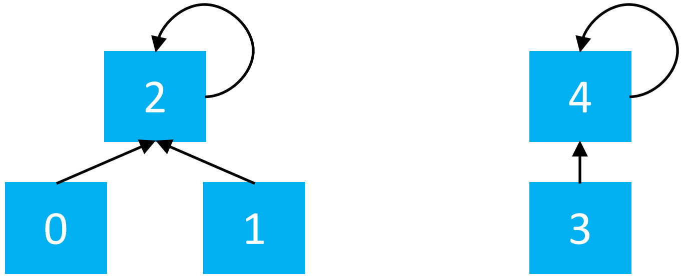


```java
public int find(int v) {
    rangeCheck(v);
    return parents[v];
}
```

- find(0) == 2
- find(1) == 2
- find(3) == 4
- find(2) == 2
- 时间复杂度：O(1)

Quick Union – Union

- Quick Union 的 union(v1, v2)：让 v1 的根节点指向 v2 的根节点

0	1	2	3	4
0	1	2	3	4

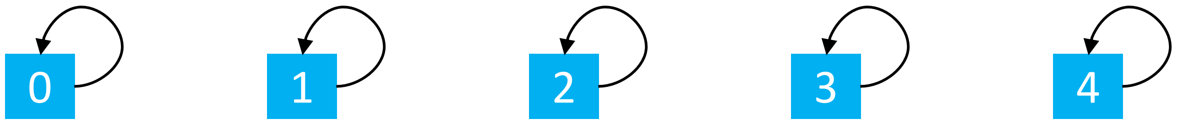

union(1, 0)

0	1	2	3	4
0	0	2	3	4

union(1, 2)

0	1	2	3	4
2	0	2	3	4

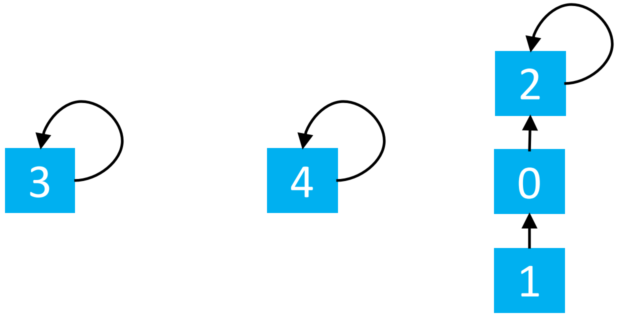

union(3, 4)

0	1	2	3	4
2	0	2	4	4

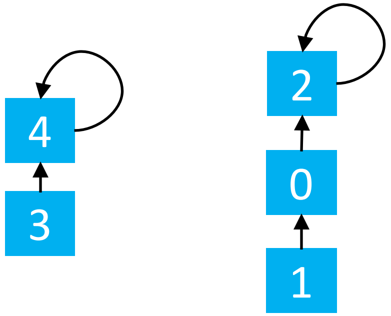

Quick Union – Union

0	1	2	3	4
2	0	2	4	4

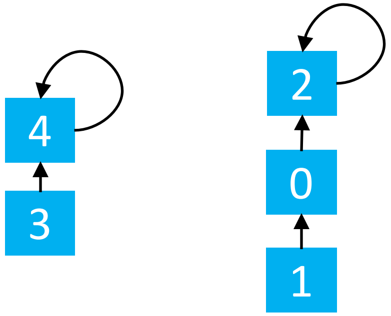

union(3, 1)

0	1	2	3	4
2	0	2	4	2

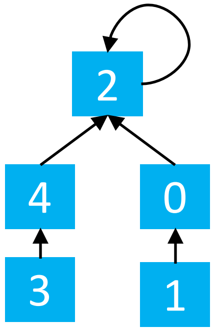

Quick Union – Union

```
public void union(int v1, int v2) {
    int p1 = find(v1);
    int p2 = find(v2);
    if (p1 == p2) return;

    parents[p1] = p2;
}
```

- 时间复杂度：O(logn)

Quick Union – Find

0	1	2	3	4
2	0	2	4	2

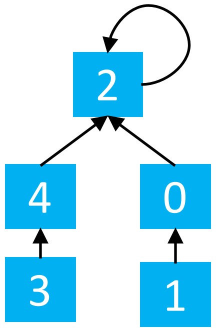


```java
public int find(int v) {
    rangeCheck(v);
    while (v != parents[v]) {
        v = parents[v];
    }
    return v;
}
```

- find(0) == 2
- find(1) == 2
- find(3) == 2
- find(2) == 2
- 时间复杂度：O(logn)

Quick Union – 优化

■ 在Union的过程中，可能会出现树不平衡的情况，甚至退化成链表

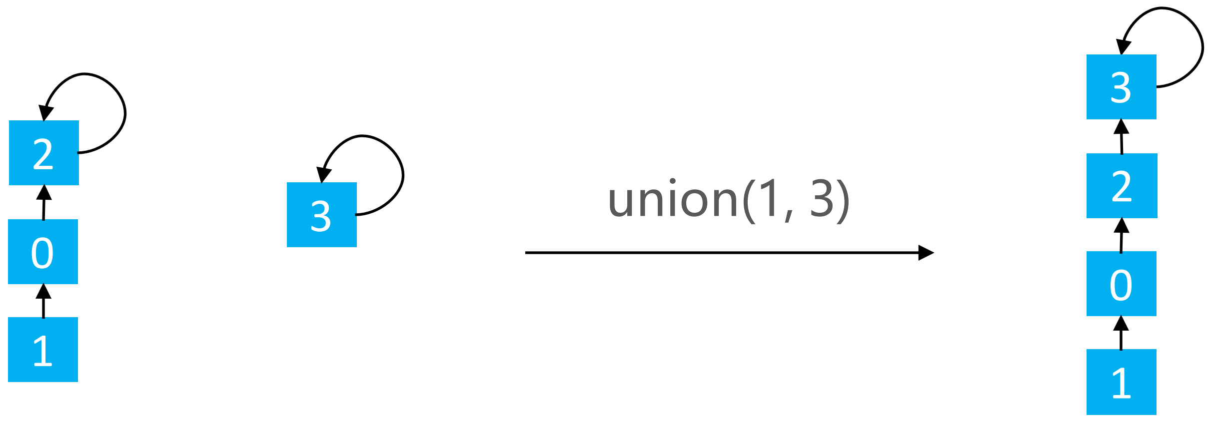

■ 有2种常见的优化方案

□ 基于size的优化：元素少的树 嫁接到 元素多的树

□ 基于rank的优化：矮的树 嫁接到 高的树

Quick Union – 基于size的优化

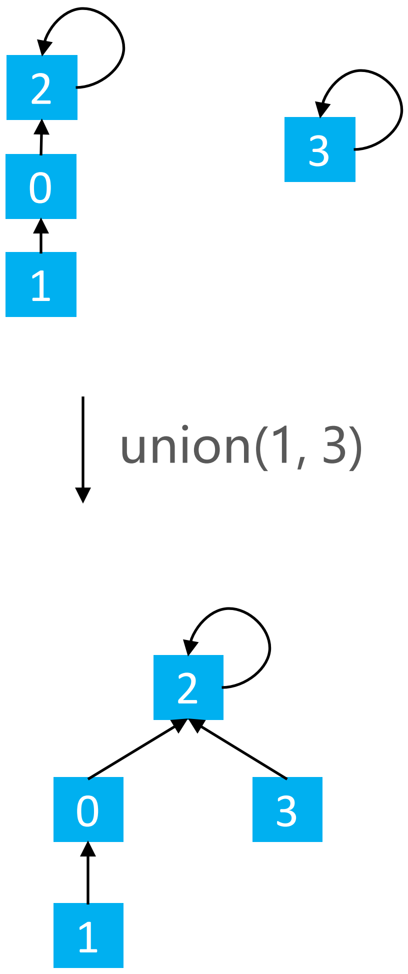


```java
sizes = new int[capacity];
for (int i = 0; i < sizes.length; i++) {
    sizes[i] = 1;
}
```

```java
private int[] sizes;
public void union(int v1, int v2) {
    int p1 = find(v1);
    int p2 = find(v2);
    if (p1 == p2) return;

    if (sizes[p1] < sizes[p2]) {
        parents[p1] = p2;
        sizes[p2] += sizes[p1];
    } else {
        parents[p2] = p1;
        sizes[p1] += sizes[p2];
    }
}
```

Quick Union – 基于size的优化

■ 基于size的优化，也可能会存在树不平衡的问题

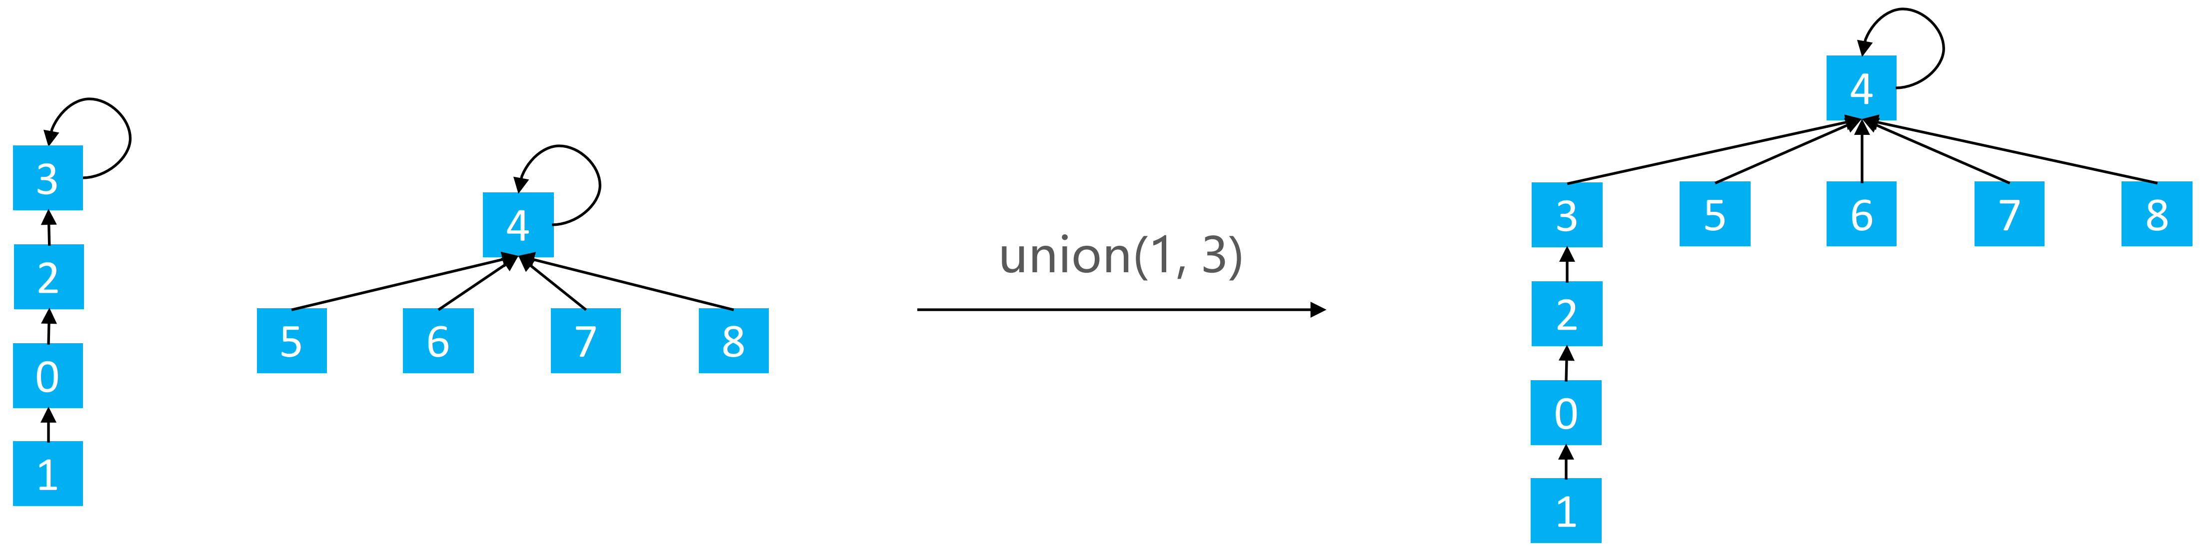

Quick Union – 基于rank的优化

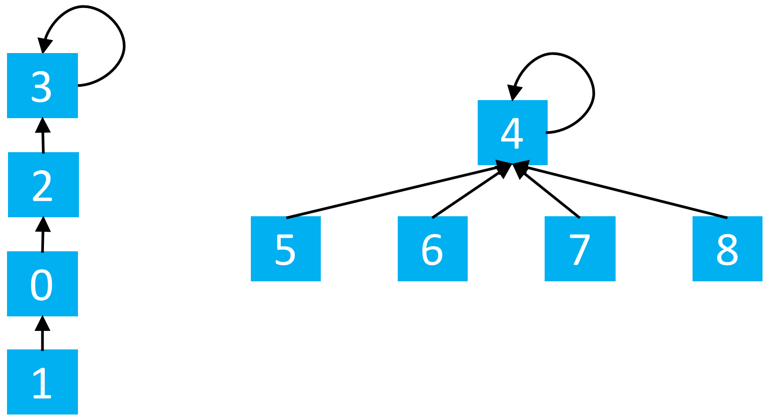

union(1, 3)

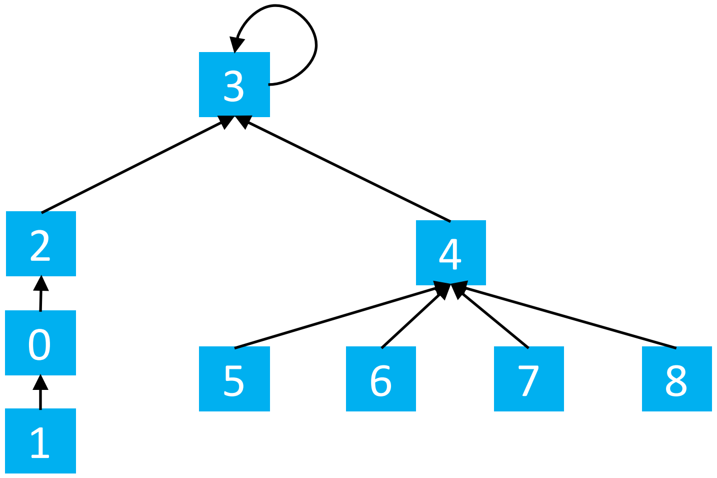


```java
ranks = new int[capacity];
for (int i = 0; i < ranks.length; i++) {
    ranks[i] = 1;
}
```

```java
private int[] ranks;
public void union(int v1, int v2) {
    int p1 = find(v1);
    int p2 = find(v2);
    if (p1 == p2) return;

    if (ranks[p1] < ranks[p2]) {
        parents[p1] = p2;
    } else if (ranks[p2] < ranks[p1]) {
        parents[p2] = p1;
    } else {
        parents[p1] = p2;
        ranks[p2]++;
    }
}
```

路径压缩（Path Compression）

■ 虽然有了基于rank的优化，树会相对平衡一点

■ 但是随着Union次数的增多，树的高度依然会越来越高

□ 导致find操作变慢，尤其是底层节点（因为find是不断向上找到根节点）

■ 什么是路径压缩?

□ 在find时使路径上的所有节点都指向根节点，从而降低树的高度

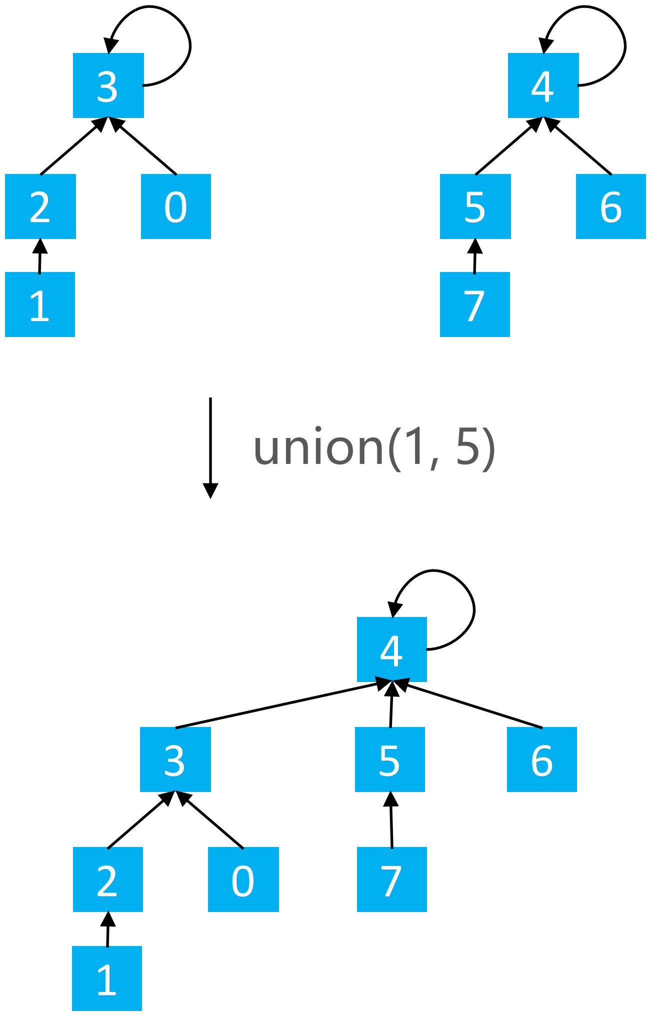

find(1)

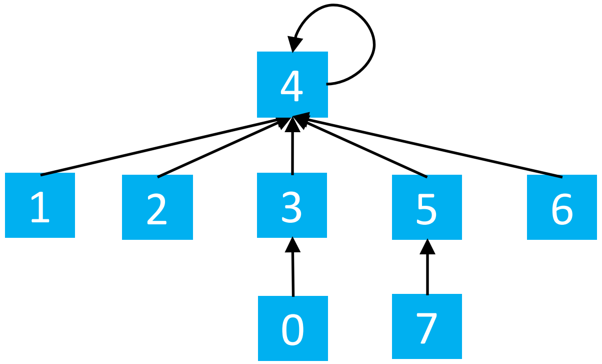

find(0)、find(7)

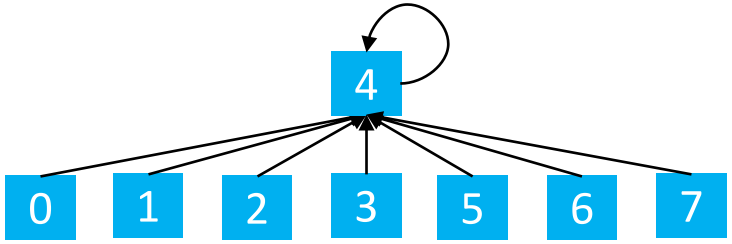

路径压缩（Path Compression）

```java
public int find(int v) {
    rangeCheck(v);
    if (parents[v] != v) {
        parents[v] = find(parents[v]);
    }
    return parents[v];
}
```

■ 路径压缩使路径上的所有节点都指向根节点，所以实现成本稍高

■ 还有2种更优的做法，不但能降低树高，实现成本也比路径压缩低

□ 路径分裂（Path Spliting）

□ 路径减半（Path Halving）

■ 路径分裂、路径减半的效率差不多，但都比路径压缩要好

路径分裂（Path Spliting）

- 路径分裂：使路径上的每个节点都指向其祖父节点（parent的parent）

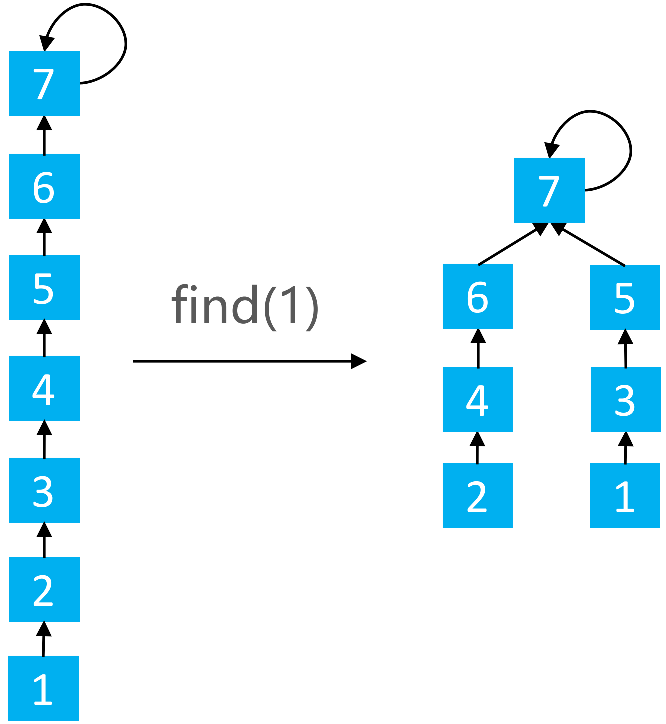


```java
public int find(int v) {
    rangeCheck(v);
    while (v != parents[v]) {
        int parent = parents[v];
        parents[v] = parents[parent];
        v = parent;
    }
    return v;
}
```

路径减半（Path Halving）

- 路径减半：使路径上每隔一个节点就指向其祖父节点（parent的parent）

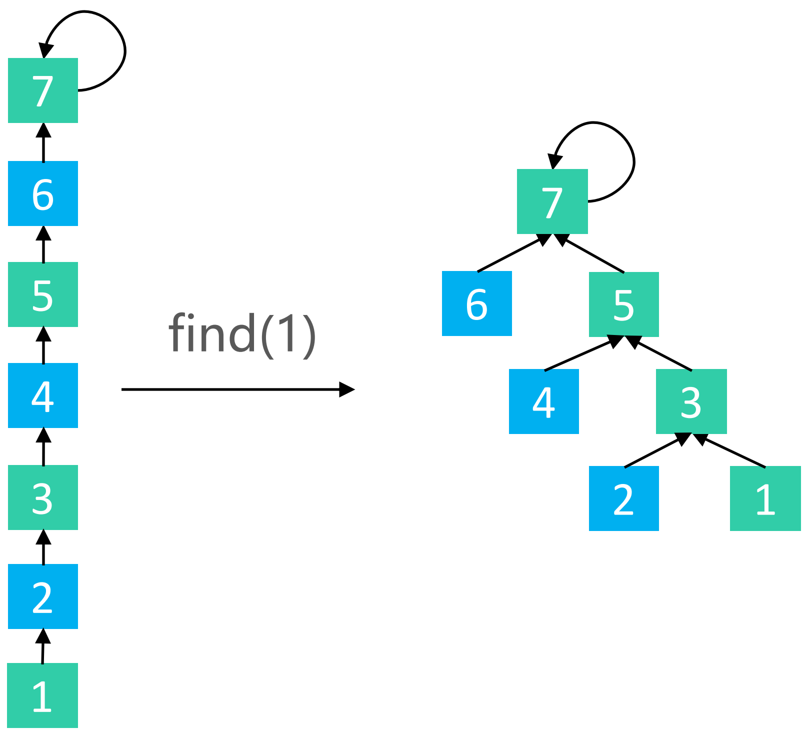


```
public int find(int v) {
    rangeCheck(v);
    while (v != parents[v]) {
        parents[v] = parents[parents[v]];
        v = parents[v];
    }
    return v;
}
```

总结

- 摘自《维基百科》： https://en.wikipedia.org/wiki/Disjoint-set_data_structure#Time_complexity

Using both *path* ***compression***, ***splitting***, *or* ***halving*** and *union by* ***rank*** *or* ***size*** ensures that the amortized time per operation is only $O(\alpha(n))$,[4][5] which is optimal,[6] where $\alpha(n)$ is the inverse Ackermann function. This function has a value $\alpha(n) < 5$ for any value of n that can be written in this physical universe, so the disjoint-set operations take place in essentially constant time.

- 大概意思是
- 使用路径压缩、分裂或减半 + 基于rank或者size的优化
- ✓ 可以确保每个操作的均摊时间复杂度为 $O(\alpha(n))$，$\alpha(n) < 5$

- 个人建议的搭配
- ✓ Quick Union
- ✓ 基于 rank 的优化
- ✓ Path Halving 或 Path Spliting

自定义类型

- ■ 之前的使用都是基于整型数据，如果其他自定义类型也想使用并查集呢?
- □ 方案一：通过一些方法将自定义类型转为整型后使用并查集（比如生成哈希值）
- □ 方案二：使用链表+映射（Map）